

Projekt 3 - Weryfikacja głosu na podstawie współczynników mel-cepstralnych MFCC

Andrzej Wrzesiński

Maj 2026

Spis treści

1	Wstęp	3
2	Implementacja algorytmu wyznaczania MFCC	3
3	Wyznaczanie progu granicznego w skali prawdopodobieństwa. Ocena działania systemu	4
4	Wnioski	6

1 Wstęp

Projekt 3. polegał na ponownym rozszerzeniu rozwijanej w ramach przedmiotu aplikacji. Została ona dodatkowo wsparta o moduł do weryfikacji głosu osoby. Polega on na możliwości udostępnienia dwóch plików WAV - źródła głosu wzorcowego oraz nagrania poddawanego weryfikacji. Program ocenia, czy ten drugi głos jest wystarczająco podobny do źródłowego, by stwierdzić, że należą one do tej samej osoby.

Wyznaczanie miary podobieństwa oparte jest na wyznaczanych współczynnikach mel-cepstralnych MFCC dla wszystkich ramek obydwu głosów. Ponieważ bardzo często może dojść do sytuacji, że nagrania są różnej długości tak, że liczba ramek, z których się składają jest różna - współczynniki te w ramach jednego nagrania są dla wszystkich ramek uśredniane i jest zwracany wektor ze średnimi arytmetycznymi. Miara podobieństwa głosów definiowana jest jako odległość euklidesowa obydwu wektorów średnich obydwu nagrań.

Poza implementacją przeprowadziłem serię eksperymentów, by określić jakość utworzonego modułu do weryfikacji oraz przede wszystkim, by znaleźć najlepszy możliwy próg graniczny rozróżniania głosów, czyli graniczną odległość euklidesową, od której dla większych wartości głosy powinny zostać rozróżnione.

2 Implementacja algorytmu wyznaczania MFCC

Implementacja wyznaczania MFCC polegała na utworzeniu kilku funkcji reprezentujących etapy potoku przetwarzania sygnału, aby wydobyć szukane współczynniki. Wszystkie kolejne etapy algorytmu są opisane poniżej

- **Etap preemfazy.** Jest to wstępna filtracja sygnału, aby osłabić jego składowe o niższych częstotliwościach a wzmocnić te o wyższych. Filtracja działa w zakresie całego przekazywanego sygnału. Dla n -tej próbki przy przyjęciu, że x_n oznacza wartość próbki przed preemfazą, a x'_n po, preemfaza przedstawiana jest wzorem

$$x'_n = x_n - \alpha x_{n-1}$$

Wartość współczynnika α dla celów projektu przyjęta została za 0.97.

- **Ramkowanie i okienkowanie sygnału wraz z jego poddaniem działaniu FFT w celu wyznaczenia widma mocy $|FFT|^2$.** Podobnie jak dla funkcjonalności w poprzednim projekcie sygnał ulega procesowi ramkowania, a następnie okienkowania. Zastosowane w tym przypadku zostało okno Hamminga. Następnie, przy pomocy algorytmu Szybkiej Transformaty Fouriera (FFT) wydobywane jest widmo częstotliwościowe sygnału. Na jego podstawie wyznaczane jest szukane widmo mocy, które polega na podniesieniu do drugiej potęgi wartości wydobytego widma amplitudowego.
- **Udział filtrów w skali melowej.** Do tego procesu wykorzystywany jest ciąg filtrów trójkątnych. Używane są do wyznaczenia energii pasm częstotliwościowych. Granice

tych pasm wyznaczane są liniowo w skali melowej, której wzór jest następujący

$$M = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right)$$

Filtry trójkątne działają w ten sposób, że w środku każdego pasma amplituda osiąga maksymalną wartość, czyli wartość filtra dla danego pasma w punkcie centralnym wynosi 1 i liniowo maleje, oddalając się w stronę jego granic, dla których osiąga wartość 0, tak samo, jak poza nimi. Tym samym wartości filtrów są nieujemne - dodatnie w każdym reprezentowanym paśmie i zerowe poza nim.

Dla każdej ramki uzyskanego widma mocy sygnału wyznaczane są energie w każdym wyznaczonym wcześniej paśmie częstotliwości. Liczba tych pasm, a tym samym filtrów trójkątnych wynosi 20. Oznaczając H_m m-ty filtr, N - rozmiar ramki ($N = 1024$), X_r - widmo ramki, energię dla m-tego pasma S_m otrzymamy przez zsumowanie mocy próbek widma mocy ramki, przemnażając ją przez odpowiadającą jej wartość filtra:

$$S_m = \sum_{k=1}^N \left(|X_r(k)|^2 H_m(k) \right)$$

- **Logarytmizacja energii.** Energie każdego pasma są logarytmizowane w celu zmniejszenia wrażliwości na różnice głośności sygnałów oraz modelowania nieliniowej wrażliwości zmysłu słuchu człowieka.
- **Dyskretna transformata cosinusowa (DCT)** Zastosowanie DCT jest ostatnim etapem algorytmu a jej wyniki są gotowymi współczynnikami MFCC wykorzystywanymi dalej w celu weryfikacji głosu. Wykorzystywany w tym celu wzór jest następujący:

$$c_i = \sqrt{\frac{2}{M}} \sum_{m=1}^M \log(S_m) \cos \left(\frac{\pi i}{M} \left(m - \frac{1}{2} \right) \right)$$

gdzie i jest numerem współczynnika, a M - liczbą filtrów. Współczynnik c_0 jest pomijany w dalszych rozważaniach i zwracane są te pozostałe.

3 Wyznaczanie progu granicznego w skali prawdopodobieństwa. Ocena działania systemu

Do weryfikacji głosu stworzyłem dodatkową klasę komponentu, wewnątrz którego wyznaczana jest miara podobieństwa. Metoda zwracająca współczynniki MFCC zwraca je w postaci wektora wektorów - każdy wektor zawiera wartości współczynników dla każdej kolejnej ramki. Dla sygnału źródłowego oraz sygnału do weryfikacji obliczany jest pojedynczy wektor zawierający uśrednione wartości każdego współczynnika względem wszystkich ramek. Otrzymywane są więc dwa wektory o tej samej długości ze względu na tę samą liczbę współczynników. Miarą podobieństwa jest odległość euklidesowa tych wektorów. Dla odpowiednio niskich

wartości system powinien stwierdzić, że sygnału dotyczą tego samego głosu, w przeciwnym razie mają one się różnić. Oprócz wyświetlanej informacji TAK lub NIE przedstawiana jest dodatkowo uzyskana odległość. Celem eksperymentu była nie tylko ocena korelacji tej wartości z weryfikacją głosu, lecz również zidentyfikowanie odpowiedniego progu, dla którego system zwraca najbardziej wiarygodne wyniki.

Eksperymenty oparłem na porównywaniu nagrań pochodzących z bazy studentów zapisanych na przedmiot, którzy udostępnili znormalizowane ścieżki nagrań swojego głosu. W celu uzyskania większej wiarygodności, porównywałem ze sobą sygnały reprezentujące te same wymawiane frazy, na przykład dwa nagrania słowa "zero", czy dwa nagrania zdania "Ala ma rudego kota". Ponieważ każdy student nagrywał wszystkie frazy dwukrotnie, możliwe było również poprawne zweryfikowanie tego eksperymentu w obrębie tej samej osoby.

Przy ocenie systemu zauważyłem, że dla przeważającej większości testów weryfikacje nagrań tego samego głosu osiągają istotnie mniejsze wartości odległości euklidesowej niż dla głosów różnych. Odległości tych samych głosów zwykle mają wartości nie przekraczające 0.4 – 0.5, podczas gdy dla różnych głosów są one większe - najmniejsze wartości wydają się osiągać przeważnie przynajmniej ok. 0.5, a nie kiedy osiągają nawet więcej niż 1.

Podczas gdy testy różnych głosów osiągają wysokie wartości, to dla tych samych głosów nie zawsze wyniki są niskie, odpowiadające wysokiej mierze podobieństwa i czasami mogą osiągać większe odległości od siebie. Powodem takiego zróżnicowania mogą być różnice w ilości cichych, bezdźwięcznych bądź zaszumionych miejsc dla obydwu nagrań, co odpowiadałoby zaburzeniom wartości współczynników i różnicy w wynikach.

Po serii testów uznałem, że system wyznacza najbardziej wiarygodne wyniki dla progu odległości równej 0.47.

Poniżej zostały przedstawione trzy tabele po trzy porównania dla trzech różnych nagrań referencyjnych.

Numer studenta	Odległość euklidesowa	Wynik TAK lub NIE
1	0.1563	TAK
5	0.6646	NIE
23	1.0930	NIE

Tabela 1: Porównania głosów dla słowa "zero" i referencyjnego głosu osoby nr 1

Numer studenta	Odległość euklidesowa	Wynik TAK lub NIE
2	0.1386	TAK
13	0.4807	NIE
25	0.5517	NIE

Tabela 2: Porównania głosów dla słowa "siedem" i referencyjnego głosu osoby nr 2

Dla każdego nagrania referencyjnego wykonałem po jednym teście dla tego samego głosu oraz po dwa dla różnych. Zgodnie z oczekiwaniami system poprawnie rozpoznał relacje

Numer studenta	Odległość euklidesowa	Wynik TAK lub NIE
7	0.2119	TAK
10	1.2763	NIE
28	0.7471	NIE

Tabela 3: Porównania głosów dla słowa "benzyna" i referencyjnego głosu osoby nr 7

dla wszystkich par nagrań i widać znaczne różnice w odległościach między tymi samymi a różnymi głosami.

4 Wnioski

System do weryfikacji głosu na podstawie współczynników mel-cepstralnych MFCC w znacznej większości przypadków zwraca zadowalające wyniki. Przede wszystkim poprawnie odróżnia głosy innych osób. Minimalnie gorzej sprawuje się dla nagrań tych samych głosów, lecz w znacznej większości przypadków również poprawnie przewiduje poprawną relację. Powodem, dla którego odległości euklidesowe dla tych samych głosów są czasami tak duże najprawdopodobniej jest zróżnicowanie ilości zaszumionych, cichych lub bezdźwięcznych fragmentów sygnału, które mogą wpływać na zaburzenie wartości otrzymywanych współczynników MFCC. Dodatkowo, zdefiniowany próg graniczny podobieństwa został wyznaczony empirycznie i w rzeczywistości ta granica może być inna. Nie mniej jednak w znacznej większości przypadków system osiąga poprawne wyniki i wydaje się dobrze weryfikować głos danej osoby.